

# Projeto de redes complexas

## Detecção de domínios funcionais

(Dated: 17 de junho de 2026)

*Objetivo.* Consolidar os conceitos de modelagem de redes, medidas de centralidade e detecção de comunidades, aplicando-os à análise estrutural de proteínas.

A proteína de interesse é o complexo do vírus da adeno-vírus humano 5 (PDB ID: 6B1T), que possui aproximadamente 10 GB quando carregado em memória. Devido a essa restrição, recomenda-se a realização de testes iniciais com proteínas menores e, se necessário, selecionem uma proteína-alvo alternativa de tamanho moderado que contenha pelo menos quatro agrupamentos estruturais distintos e permita visualização 3D clara das comunidades identificadas.

O projeto deve ser conduzido individualmente, com relatórios próprios, embora discussões entre colegas sejam permitidas e devam ser explicitamente declaradas na submissão. O uso de IA deve ser declarado na produção de códigos e de relatórios, com inclusão do modelo e versão do LLM, temperatura e se possível prompt utilizado. O uso inadequado ou excessivo poderá impactar na nota final do projeto.

### ETAPAS

1. *Obtenção e preparação dos dados.* Baixe o arquivo PDB da estrutura 6B1T a partir de <https://www.rcsb.org/structure/6B1T> (opção de download do pacote comprimido tar.gz). Para testes preliminares, selecione proteínas menores disponíveis no mesmo repositório, que permitam validar a cadeia de processamento sem sobrecarga de memória.
2. *Leitura e parsing do arquivo PDB.* Utilize pacote específico ou implemente um leitor para extrair as informações de cada átomo.
3. *Construção da rede.* Modele a proteína como um grafo não-dirigido, podendo ser unitário ou ponderado. A definição das arestas **pode** considerar os seguintes critérios:
  - distância espacial;
  - pertencer ao mesmo resíduo de aminoácido;
  - diferentes cadeias;

- afinidade entre resíduos (i.e., hidrofobicidade, carga, capacidade de formar pontes de H, dados tabelados);
- entropia mútua e correlação espacial;
- autoencoder + classificador  $n \rightarrow 1$ ;
- à critério do aluno;

A justificativa detalhada da modelagem deve constar no relatório final, e deve ter uma boa fundamentação.

4. *Análise topológica da rede.* Calcule e interprete as seguintes medidas:
  - distribuição de graus ;
  - centralidades convenientes ;

Relacione os resultados com a estrutura tridimensional esperada.

5. *Detecção de comunidades.* Aplique ao menos um algoritmo de detecção de comunidades (ex.: Louvain, Infomap, ou Bipartição espectral). Reporte o número de comunidades encontradas.
6. *Validação biológica.* A detecção ideal é aquela que reproduz as famílias de proteínas anotadas para 6B1T, disponíveis em <https://www.rcsb.org/annotations/6B1T>. A detecção mínima esperada consiste em separar as duas principais unidades estruturais: o penton (base) e o hexon (capsídeo). A correção visual das comunidades pode ser verificada sobrepondo os clusters à estrutura 3D no visualizador do RCSB (<https://www.rcsb.org/3d-view/6B1T>).
7. *Estratégia de teste.* Desenvolva e valide todo o pipeline em uma ou mais proteínas de pequeno porte (menos de 1000-10000 resíduos) antes de executar sobre o alvo principal. Documente os parâmetros ajustados (limiar de distância, esquema de ponderação) e os resultados intermediários.

## ENTREGAS

Todo o código-fonte deve ser disponibilizado em um repositório público no GitHub, contendo um `README.md` com instruções claras de instalação e execução. Acompanhe o repositório com uma apresentação de slides (formato PDF) que descreva, de forma sucinta, o passo a passo para rodar o projeto, incluindo capturas de tela dos resultados esperados para a proteína de teste (dirty-and-quick).

O relatório final, em formato PDF, deve conter:

- Descrição detalhada da modelagem de rede, com justificativas para cada escolha;
- Resultados das análises de centralidade e distribuição de graus para a proteína de teste e para o alvo;
- Resultados do algoritmos de comunidade utilizados;
- Avaliação quantitativa e qualitativa da correspondência entre as comunidades detectadas e as anotações funcionais/estruturais conhecidas;
- Declaração explícita de quaisquer discussões com colegas, especificando o escopo da colaboração.

## CRITÉRIOS DE AVALIAÇÃO

A nota será atribuída de acordo com os seguintes níveis de desempenho:

- **0 – 4.9:** Os testes iniciais e a aplicação no alvo estão incompletos ou não funcionam;
- **5 – 6.9:** Os testes iniciais foram concluídos com sucesso, mas a execução no alvo principal apresenta falhas ou não converge;
- **7 – 8.9:** Os testes iniciais e a aplicação no alvo foram realizados integralmente, porém as comunidades detectadas não correspondem às famílias anotadas corretamente;
- **9 – 10:** Todos os testes e a execução no alvo estão completos, e as comunidades identificadas reproduzem com fidelidade as famílias de proteínas anotadas (ou os domínios estruturais conhecidos, no caso de proteína alternativa).

O alvo deve ser preferencialmente 6B1T mas outra pode ser utilizada, caso a memória seja insuficiente (deve conter ao menos 4 anotações/grupos funcionais).

*Observações finais* O relatório, os slides, e os links para o repositório devem ser enviados por email [gilberto.nakamura@ufu.br](mailto:gilberto.nakamura@ufu.br). Códigos em Rust/C/C++/Python/R e Julia serão aceitos.