

Universidade Federal de Uberlândia
Faculdade de Computação
Programa de Pós-Graduação em Ciência da Computação

**Modelagem de Redes Complexas para Detecção de
Comunidades: Um Estudo de Caso da Proteína
6B1T do Adenovírus Humano 5**

Projeto Final da Disciplina de Redes Complexas
Discente: Larissa Alves Trevilato
Prof. Dr. Gilberto Nakamura

SUMÁRIO

1 Introdução	1
2 Objetivos	1
2.1 Objetivo Geral	1
2.2 Objetivos Específicos	1
3 Materiais e Métodos	2
3.1 Dados Utilizados	2
3.2 Proteína de Teste	2
3.3 Proteína-Alvo 6B1T	3
3.4 Modelagem da Rede	4
3.4.1 Definição dos Nós	4
3.4.2 Definição das Arestas	5
3.4.3 Escolha do Limiar de Distância	5
3.5 Metodologia Computacional	6
4 Resultados	7
4.1 Validação do Pipeline Utilizando a Proteína de Teste	7
4.2 Construção da Rede da Proteína 6B1T	8
4.3 Avaliação do Limiar de Distância	9
4.4 Análise Topológica	11
4.4.1 Distribuição de graus	11
4.4.2 Centralidades	12
4.5 Detecção de Comunidades	14
4.6 Validação Biológica e Estrutural	16
5 Limitacoes	17
6 Declaração de Colaboração e Uso de Inteligência Artificial	18
7 Conclusão	18
Referencias	21

1 - Introdução

Proteínas desempenham funções essenciais em praticamente todos os processos biológicos. Essas funções dependem diretamente de sua organização estrutural, uma vez que a disposição espacial dos aminoácidos determina interações responsáveis pela estabilidade e pela atividade biológica da molécula.

Nos últimos anos, a Teoria de Redes Complexas tem sido empregada como uma ferramenta alternativa para representar e analisar sistemas biológicos, permitindo estudar relações entre elementos de um sistema por meio de vértices e arestas [1], [3]. Nessa abordagem, propriedades estruturais podem ser investigadas a partir de medidas topológicas, como grau, centralidade, conectividade e formação de comunidades.

No contexto de proteínas, uma abordagem amplamente utilizada consiste em representar resíduos de aminoácidos como nós da rede e estabelecer conexões entre resíduos espacialmente próximos [5]–[7]. Essa representação gera uma rede de contatos que preserva informações relevantes sobre a organização tridimensional da molécula, possibilitando a análise de regiões estruturalmente associadas e potenciais agrupamentos funcionais.

Entre os métodos de detecção de comunidades, o algoritmo Louvain destaca-se por sua eficiência computacional e pela capacidade de identificar grupos de vértices fortemente conectados por meio da maximização da modularidade [4]. Em redes de proteínas, esses agrupamentos podem estar associados a regiões estruturalmente organizadas, fornecendo uma visão complementar às análises geométricas tradicionais.

Neste trabalho, foi desenvolvido uma rotina computacional para modelar proteínas como redes complexas utilizando informações estruturais obtidas a partir de arquivos de extensão PDB. Inicialmente, a metodologia foi validada com uma proteína de pequeno porte. Em seguida, o mesmo procedimento foi aplicado à estrutura 6B1T, correspondente ao Adenovírus Humano tipo 5, com o objetivo de investigar sua organização topológica e identificar comunidades estruturais a partir da rede de contatos construída.

2 - Objetivos

2.1 - Objetivo geral

Modelar a estrutura tridimensional de proteínas como uma rede complexa, aplicando medidas de análise topológica e o algoritmo de detecção de comunidades Louvain para investigar a organização estrutural da proteína 6B1T do Adenovírus Humano tipo 5.

2.2 - Objetivos específicos

- Desenvolver uma rotina computacional para leitura e processamento de arquivos no formato PDB.
- Representar a proteína como um grafo não direcionado, utilizando resíduos de aminoácidos como vértices e contatos espaciais entre resíduos como arestas.

- Validar toda a metodologia utilizando uma proteína de pequeno porte antes da aplicação à proteína-alvo.
- Avaliar o impacto do limiar de distância na construção da rede por meio de experimentos utilizando diferentes valores de cutoff.
- Calcular medidas topológicas da rede, incluindo distribuição de graus e métricas de centralidade adequadas ao porte das estruturas analisadas.
- Aplicar o algoritmo Louvain para identificar comunidades na rede correspondente à proteína.
- Analisar qualitativamente a correspondência entre as comunidades detectadas e a organização estrutural observada na proteína 6B1T.

3 - Materiais e Métodos

3.1 - Dados utilizados

Os dados utilizados neste trabalho foram obtidos a partir do **Protein Data Bank (PDB)**, principal repositório público de estruturas tridimensionais de proteínas, ácidos nucleicos e complexos macromoleculares [8]. As estruturas são disponibilizadas em formato padronizado (PDB), contendo informações detalhadas sobre os átomos, resíduos, cadeias polipeptídicas e coordenadas cartesianas tridimensionais necessárias para a reconstrução da geometria molecular.

O desenvolvimento da metodologia foi dividido em duas etapas. Inicialmente, todo o pipeline computacional foi validado utilizando uma proteína de pequeno porte, permitindo verificar o correto funcionamento das etapas de leitura do arquivo PDB, extração das coordenadas dos resíduos, construção da rede, cálculo das métricas topológicas e detecção de comunidades. Após essa etapa de validação, a mesma metodologia foi aplicada à proteína-alvo proposta no trabalho.

Toda a implementação foi desenvolvida na linguagem **Python**, empregando bibliotecas consolidadas para computação científica e análise de redes. A leitura e interpretação dos arquivos PDB foram realizadas utilizando a biblioteca **Biopython** [10]. A construção da rede e o cálculo das métricas topológicas foram realizados com a biblioteca **NetworkX** [11]. A manipulação dos dados foi realizada utilizando **NumPy** [13] e **Pandas** [14], enquanto a busca eficiente por vizinhos espaciais foi implementada por meio da estrutura **KD-Tree**, disponibilizada pela biblioteca **SciPy** [12].

Para a geração dos gráficos foi utilizada a biblioteca **Matplotlib**, enquanto a inspeção visual da estrutura tridimensional da proteína e das comunidades detectadas foi realizada utilizando a biblioteca **py3Dmol**, permitindo sobrepor as comunidades identificadas diretamente sobre o modelo tridimensional da proteína.

3.2 - Proteína de teste

Antes da aplicação da metodologia à proteína-alvo, todo o pipeline computacional foi validado utilizando a proteína **Ubiquitina (PDB ID: 1UBQ)**, disponível no Protein Data Bank [8]. A ubiquitina foi escolhida por apresentar uma estrutura tridimensional relativamente

simples e um número reduzido de resíduos, tornando seu processamento computacional rápido e adequado para a validação das etapas de desenvolvimento.

A utilização de uma proteína de pequeno porte permitiu verificar individualmente cada etapa do pipeline implementado, incluindo a leitura do arquivo PDB, a extração das coordenadas dos resíduos, a construção da rede de contatos, o cálculo das métricas topológicas e a aplicação do algoritmo Louvain para detecção de comunidades. Essa estratégia reduziu significativamente o tempo necessário para depuração da implementação e permitiu identificar eventuais inconsistências antes da execução sobre uma estrutura de maior porte.

Além da validação funcional do pipeline, a proteína de teste possibilitou a execução de medidas de centralidade computacionalmente mais custosas, como centralidade de intermediação (*betweenness centrality*) e centralidade de proximidade (*closeness centrality*). A obtenção desses resultados permitiu confirmar o correto funcionamento das rotinas implementadas e serviu como etapa preliminar para a aplicação da metodologia na proteína-alvo.

Após a validação de todas as etapas, a mesma sequência de processamento foi empregada na estrutura 6B1T, preservando os critérios de modelagem adotados e os parâmetros utilizados para a construção da rede.

3.3 - Proteína-alvo

Após a validação da metodologia utilizando a proteína de teste, o pipeline computacional foi aplicado à estrutura **6B1T**, obtida a partir do **Protein Data Bank (PDB)** [8]. Essa estrutura corresponde ao capsídeo do **Adenovírus Humano tipo 5 (Human Adenovirus 5 – HAdV-5)**, determinado por microscopia crioelétrica de alta resolução [9].

Diferentemente da proteína utilizada durante a etapa de validação, a estrutura 6B1T apresenta elevada complexidade estrutural, sendo composta por um grande número de cadeias, resíduos e átomos. Essa característica representa um desafio computacional tanto para a construção da rede quanto para a aplicação das métricas de análise topológica.

A estrutura disponibilizada pelo Protein Data Bank encontra-se distribuída em dois arquivos (6b1t-pdb-bundle1.pdb e 6b1t-pdb-bundle2.pdb), os quais foram processados individualmente durante a etapa de leitura. Após a extração das informações estruturais, os resíduos provenientes dos dois arquivos foram integrados em uma única estrutura de dados, permitindo a construção de um único grafo representativo da proteína.

Ao final do processo de extração, foram identificados **12.544 resíduos contendo átomo C α** , que passaram a representar os vértices da rede construída neste trabalho. Essa representação possibilitou reduzir significativamente a complexidade computacional da análise, mantendo a organização estrutural global da proteína e tornando viável a aplicação das técnicas de análise de redes e detecção de comunidades.

A utilização da estrutura 6B1T permitiu avaliar a metodologia proposta em uma proteína de grande porte, verificando sua capacidade de representar a organização estrutural do

complexo por meio de uma rede de contatos e de identificar agrupamentos estruturais utilizando algoritmos de detecção de comunidades.

3.4 - Modelagem da rede

A etapa central deste trabalho consistiu na representação da estrutura tridimensional da proteína como uma rede complexa. Nessa abordagem, a proteína foi modelada como um grafo não direcionado e não ponderado, no qual cada vértice representa um resíduo de aminoácido e cada aresta representa uma relação de proximidade espacial entre dois resíduos.

A opção por utilizar um grafo não direcionado foi motivada pela natureza da interação considerada na modelagem. A proximidade espacial entre dois resíduos é uma relação simétrica, ou seja, se o resíduo *A* encontra-se próximo ao resíduo *B*, então o resíduo *B* também está próximo ao resíduo *A*. Dessa forma, não existe direção associada às conexões estabelecidas na rede.

A construção da rede foi baseada exclusivamente nas informações geométricas presentes nos arquivos PDB, utilizando as coordenadas tridimensionais dos resíduos para determinar a existência de conexões entre os vértices. Essa estratégia permitiu representar a organização espacial da proteína preservando suas principais relações estruturais, ao mesmo tempo em que manteve a complexidade computacional em níveis compatíveis com o porte da estrutura analisada.

As decisões adotadas durante a modelagem da rede, incluindo a definição dos vértices, o critério de estabelecimento das arestas e a escolha do limiar de distância, são descritas nas subseções a seguir.

3.4.1 - Definição dos nós

Cada vértice da rede representa um resíduo de aminoácido da proteína. Para representar espacialmente cada resíduo, foi utilizada a posição do átomo **C α** (**Carbono Alfa**), obtida diretamente a partir do arquivo PDB.

A utilização do átomo C α constitui uma abordagem amplamente empregada em estudos de redes de contatos de proteínas, pois esse átomo está presente em praticamente todos os aminoácidos e fornece uma representação consistente da posição do resíduo na cadeia polipeptídica. Dessa forma, cada resíduo é representado por um único ponto no espaço tridimensional, reduzindo significativamente a complexidade da rede quando comparado à modelagem em nível atômico.

Essa decisão foi particularmente importante para a estrutura 6B1T, que possui aproximadamente cem mil registros de átomos distribuídos em seus arquivos PDB. Caso cada átomo fosse representado como um vértice da rede, o custo computacional das análises seria significativamente maior. A representação em nível de resíduos preserva a organização estrutural global da proteína, ao mesmo tempo em que torna viável a aplicação das métricas topológicas e dos algoritmos de detecção de comunidades.

3.4.2 - Definição das arestas

As arestas da rede foram definidas utilizando um critério de proximidade espacial entre os resíduos da proteína. Para cada par de resíduos, foi calculada a distância euclidiana entre as coordenadas tridimensionais de seus respectivos átomos C α . Sempre que essa distância fosse menor ou igual ao limiar estabelecido para a construção da rede, uma aresta era criada entre os dois vértices.

Esse procedimento resulta em uma rede de contatos não direcionada e não ponderada, na qual cada aresta representa exclusivamente a existência de proximidade espacial entre dois resíduos. Assim, dois resíduos são considerados conectados quando satisfazem o critério de distância adotado, independentemente da posição que ocupam na sequência primária da proteína. Essa forma de modelagem é amplamente utilizada em estudos de redes de contatos de proteínas, pois preserva as principais relações estruturais da molécula e permite a aplicação de técnicas de análise topológica e detecção de comunidades [5]–[7].

Optou-se por utilizar uma rede não ponderada porque o objetivo deste trabalho consiste em investigar a organização estrutural da proteína por meio da conectividade entre seus resíduos. Dessa forma, o aspecto de interesse é a existência ou não de contato entre dois resíduos, e não a intensidade dessa interação. Essa representação simplifica a modelagem da rede, reduz a complexidade das análises e mantém consistência com as métricas topológicas e com o algoritmo de detecção de comunidades empregados neste estudo.

A identificação dos pares de resíduos candidatos à conexão foi realizada utilizando a estrutura de dados **KD-Tree**, disponibilizada pela biblioteca **SciPy** [12]. Essa estrutura permite realizar consultas espaciais de forma eficiente, reduzindo significativamente o custo computacional quando comparada à avaliação exaustiva de todas as combinações possíveis de resíduos. Essa otimização foi fundamental para tornar viável a construção da rede correspondente à proteína 6B1T, composta por mais de doze mil vértices.

3.4.3 - Escolha do limiar de distância

A definição do limiar de distância (*cutoff*) constitui uma das principais decisões na construção de redes de contatos de proteínas, pois determina quais pares de resíduos serão considerados conectados. Valores reduzidos produzem redes mais esparsas, enquanto valores elevados aumentam a densidade da rede, alterando diretamente suas propriedades topológicas e a estrutura das comunidades identificadas [5]–[7].

Com o objetivo de avaliar a influência desse parâmetro, foram realizados experimentos utilizando cinco valores distintos de cutoff: **6 Å, 7 Å, 8 Å, 9 Å e 10 Å**. Para cada configuração foram calculados o número de arestas, o grau médio da rede, o número de comunidades detectadas pelo algoritmo Louvain, o valor da modularidade e o tempo de execução.

Os resultados desses experimentos são apresentados e discutidos na **Seção 4.3**, na qual é realizada a comparação entre os diferentes valores de cutoff avaliados.

Com base nessa análise, foi adotado o valor de **8 Å** para a construção da rede utilizada nas análises finais. Esse limiar apresentou um equilíbrio entre conectividade, organização

modular da rede e custo computacional, produzindo uma representação estrutural consistente da proteína. Além disso, esse valor encontra-se dentro da faixa normalmente empregada em estudos de redes de contatos de proteínas [5]–[7].

3.5 - Metodologia computacional

A rotina desenvolvida neste trabalho foi estruturada em etapas independentes, permitindo sua validação utilizando uma proteína de pequeno porte antes da aplicação à proteína-alvo. Essa organização também possibilitou a reutilização das mesmas rotinas para diferentes estruturas, modificando apenas o arquivo PDB de entrada.

Inicialmente, os arquivos PDB foram processados utilizando a biblioteca **Biopython** [10], responsável pela leitura da estrutura tridimensional da proteína e pela extração das informações de interesse. Para cada resíduo contendo átomo C α foram obtidos a cadeia à qual pertence, o nome do aminoácido, sua numeração e suas coordenadas cartesianas tridimensionais.

Após a etapa de extração, os dados foram organizados em estruturas de datasets utilizando a biblioteca **Pandas** [14], facilitando sua manipulação e posterior construção da rede. Em seguida, as coordenadas tridimensionais dos resíduos foram utilizadas para construir uma estrutura **KD-Tree**, disponibilizada pela biblioteca **SciPy** [12], permitindo identificar de forma eficiente todos os pares de resíduos cuja distância fosse inferior ou igual ao valor de cutoff definido.

A partir dos pares de resíduos identificados, foi construído um grafo não direcionado e não ponderado utilizando a biblioteca **NetworkX** [11]. Cada resíduo passou a representar um vértice da rede, enquanto cada par de resíduos que satisfazia o critério de distância passou a representar uma aresta.

Após a construção da rede, foram calculadas métricas estruturais básicas, incluindo número de vértices, número de arestas, grau médio, número de componentes conectados e distribuição de graus. Também foram calculadas medidas de centralidade e aplicados algoritmos de detecção de comunidades, permitindo caracterizar a organização topológica da proteína e identificar agrupamentos estruturalmente relevantes.

A identificação de comunidades foi realizada utilizando o algoritmo **Louvain**, implementado na biblioteca **NetworkX** [4], possibilitando particionar a rede em grupos de vértices fortemente conectados por meio da maximização da modularidade.

Por fim, foram gerados gráficos estatísticos, tabelas contendo os resultados obtidos e visualizações tridimensionais das comunidades detectadas utilizando a biblioteca **py3Dmol**. Todas as etapas do pipeline foram implementadas em Python e executadas de forma idêntica tanto para a proteína de teste quanto para a proteína-alvo.




Figura 1 – Fluxograma do pipeline computacional desenvolvido neste trabalho.

4 - Resultados

4.1 - Validação do pipeline utilizando a proteína de teste

Antes da aplicação da metodologia à proteína-alvo, todo o pipeline computacional foi validado utilizando a proteína **1UBQ (Ubiquitina)**. Essa etapa teve como objetivo verificar o funcionamento de cada componente da implementação, reduzindo a possibilidade de propagação de erros para a análise da estrutura 6B1T.

Inicialmente, foi realizada a leitura do arquivo PDB e a extração das coordenadas tridimensionais dos resíduos representados pelos átomos C α . Em seguida, foi construída a rede de contatos utilizando o mesmo critério de modelagem posteriormente empregado na proteína-alvo, permitindo verificar o correto funcionamento da construção do grafo.

Sobre a rede obtida foram executadas as rotinas de cálculo das métricas topológicas, incluindo distribuição de graus, centralidade de proximidade (*closeness centrality*), centralidade de intermediação (*betweenness centrality*) e identificação de comunidades por meio do algoritmo Louvain. A execução bem-sucedida dessas etapas confirmou a consistência da implementação e a correta integração entre as bibliotecas utilizadas durante o desenvolvimento.

A Figura 2 apresenta a rede construída para a proteína 1UBQ, na qual os vértices foram coloridos de acordo com as comunidades identificadas pelo algoritmo Louvain. Embora a proteína possua dimensões reduzidas quando comparada à estrutura 6B1T, foi possível observar a formação de agrupamentos coerentes, indicando que o pipeline implementado foi capaz de representar adequadamente a organização estrutural da proteína.

Rede de contatos da proteína 1UBQ




Figura 2 – Rede de contatos da proteína 1UBQ com os vértices coloridos de acordo com as comunidades detectadas pelo algoritmo Louvain.

A validação utilizando uma proteína de pequeno porte mostrou-se importante não apenas para verificar a correção da implementação, mas também para avaliar o comportamento das métricas topológicas e confirmar que o pipeline encontrava-se apto para processar estruturas significativamente maiores, como a proteína 6B1T.

4.2 - Construção da rede da proteína 6B1T

Após a validação do pipeline utilizando a proteína de teste, a metodologia foi aplicada à estrutura 6B1T. Inicialmente, foram processados os dois arquivos PDB disponibilizados pelo Protein Data Bank, realizando a extração dos resíduos contendo átomo Cα e a integração das informações em uma única estrutura de dados.

Em seguida, foi construída a rede de contatos utilizando o critério de proximidade espacial descrito na Seção 3.4. Foram considerados como vértices todos os resíduos contendo átomo C α e foram estabelecidas conexões entre pares de resíduos cuja distância euclidiana fosse menor ou igual ao valor de cutoff adotado para as análises finais (8 Å).

A rede obtida apresentou **12.544 vértices** e **66.809 arestas**, formando um único componente conectado. O grau médio observado foi de aproximadamente **10,65**, indicando que, em média, cada resíduo estabelece contato espacial com cerca de onze outros resíduos da estrutura.

A Tabela 2 apresenta um resumo das principais características estruturais da rede construída para a proteína 6B1T, os resultados podem ser visualizados no arquivo *results/tables/6B1T_graph_statistics.csv*.

Tabela 2 – Estatísticas gerais da rede construída para a proteína 6B1T.

Métrica	Valor	Descrição
Número de vértices	12.544	Quantidade de resíduos representados na rede
Número de arestas	66.809	Número de contatos entre resíduos
Grau médio	10,65	Número médio de conexões por resíduo
Componentes conectados	1	Toda a rede é conectada
Maior componente	12.544	Inclui todos os vértices da rede

Os resultados apresentados demonstram que a metodologia proposta foi capaz de representar toda a estrutura da proteína em uma única rede conectada, preservando as relações espaciais entre os resíduos e produzindo uma base adequada para as análises topológicas e para a aplicação dos algoritmos de detecção de comunidades descritos nas seções seguintes.

4.3 - Avaliação do limiar de distância

A escolha do limiar de distância (*cutoff*) exerce influência direta sobre a estrutura da rede construída, uma vez que determina quais pares de resíduos serão considerados conectados. Para avaliar quantitativamente esse impacto, foram comparados cinco valores de cutoff: **6 Å, 7 Å, 8 Å, 9 Å e 10 Å**.

A Tabela 2 apresenta os resultados obtidos para cada configuração avaliada, incluindo o número de arestas, o grau médio da rede, o número de comunidades detectadas pelo algoritmo Louvain, a modularidade e o tempo necessário para execução. Esses resultados podem ser vistos através do arquivo *results/tables/6B1T_cutoff_tests.csv*.

Tabela 2 – Influência do valor de cutoff sobre as propriedades estruturais da rede.

Cutoff (Å)	Nós	Arestas	Grau médio	Comunidades	Modularidade	Tempo (s)
6	12544	32669	5,21	53	0,9446	2,81
7	12544	51510	8,21	41	0,9217	2,90
8	12544	66809	10,65	33	0,9044	4,57
9	12544	91484	14,59	30	0,8905	5,00
10	12544	127749	20,37	25	0,8720	6,69

Observa-se que o aumento do valor de *cutoff* produz um crescimento progressivo no número de conexões da rede, refletido tanto no aumento do número de arestas quanto no grau médio dos vértices. Como consequência, regiões anteriormente separadas passam a compartilhar conexões, reduzindo gradualmente o número de comunidades identificadas pelo algoritmo Louvain.

Também é possível observar uma diminuição gradual da modularidade à medida que o *cutoff* aumenta. Esse comportamento indica que redes mais densas tendem a apresentar comunidades menos bem definidas, uma vez que o acréscimo de conexões entre diferentes regiões da proteína reduz a separação estrutural entre os agrupamentos detectados.

A Figura 3 ilustra a variação da modularidade em função do valor de *cutoff*, evidenciando a tendência observada experimentalmente, que pode ser observada no arquivo [results/figures/6B1T_cutoff_modularity.png](#)




Figura 3 – Variação da modularidade da rede em função do valor de cutoff adotado.

Considerando conjuntamente a conectividade da rede, a quantidade de comunidades identificadas, os valores de modularidade e o custo computacional observado, o valor de **8 Å** apresentou o melhor equilíbrio entre esses critérios, sendo adotado nas análises apresentadas nas seções seguintes.

4.4 - Análise topológica

4.4.1 - Distribuição de graus

A distribuição de graus constitui uma das principais medidas utilizadas na caracterização de redes complexas, descrevendo como as conexões encontram-se distribuídas entre os vértices da rede [1], [3]. No contexto deste trabalho, essa análise permite avaliar como os contatos espaciais encontram-se distribuídos entre os resíduos da proteína.

A Figura 4, obtida através do arquivo *results/figures/6B1T_degree_distribution.png*, apresenta o histograma da distribuição de graus para a rede correspondente à proteína 6B1T. À esquerda é apresentado o histograma da distribuição dos graus, enquanto à direita é apresentada a mesma distribuição em escala log-log, permitindo uma análise complementar do comportamento da rede.




Figura 4 – À esquerda é apresentado o histograma da distribuição dos graus, enquanto à direita é apresentada a mesma distribuição em escala log-log, permitindo uma análise complementar do comportamento da rede.

Observa-se que a maior parte dos resíduos apresenta grau intermediário, concentrando-se aproximadamente entre 8 e 14 conexões. Em contrapartida, poucos resíduos apresentam grau significativamente inferior ou superior à média observada, indicando uma distribuição relativamente concentrada das conexões na estrutura da proteína.

A representação em escala log-log evidencia a presença de uma cauda na distribuição dos graus, característica frequentemente observada em redes biológicas [1], [3]. Entretanto, não foram realizados testes estatísticos para verificar aderência a uma distribuição do tipo lei de potência, uma vez que esse não constitui o objetivo principal deste trabalho.

De maneira geral, os resultados indicam que a modelagem adotada foi capaz de representar adequadamente a organização dos contatos espaciais entre os resíduos da proteína, produzindo uma rede conectada e estruturalmente consistente para as análises subsequentes.

4.4.2 - Medidas de centralidade

Além da distribuição de graus, foram calculadas diferentes medidas de centralidade com o objetivo de identificar resíduos estruturalmente relevantes na rede correspondente à proteína 6B1T. Foram avaliadas a centralidade de grau (*Degree Centrality*), a centralidade de autovetor (*Eigenvector Centrality*), a centralidade de proximidade (*Closeness Centrality*) e a centralidade de intermediação (*Betweenness Centrality*). Devido ao elevado porte da rede, a centralidade de intermediação foi obtida por meio de uma aproximação baseada em amostragem, reduzindo o custo computacional sem comprometer a análise qualitativa dos resultados.

A Tabela 3 apresenta um resumo estatístico das medidas de centralidade calculadas para todos os resíduos da proteína. Os valores foram extraídos do arquivo *results/tables/6B1T_centralities.csv*. Os resíduos de maior valor para cada métrica foram obtidos pela ordenação decrescente das colunas *degree centrality*, *eigenvector centrality*, *betweenness centrality approx* e *closeness centrality*.

Tabela 3 – Estatísticas descritivas das medidas de centralidade calculadas para a proteína 6B1T.

Medida	Resíduo (cadeia)	Valor
Degree Centrality	GLY 839 (cadeia A)	0,001595
Eigenvector Centrality	PRO 173 (cadeia I)	0,155741
Betweenness Centrality	ASN 344 (cadeia C)	0,051406
Closeness Centrality	ARG 67 (cadeia K)	0,070511

Os resultados da centralidade de grau mostraram que os resíduos mais conectados apresentaram grau máximo igual a 20, aproximadamente o dobro do grau médio observado para a rede. Entre os resíduos mais destacados encontram-se aminoácidos como **LEU 543**, **PRO 173**, **GLY 839**, **ALA 172** e **SER 802**, distribuídos em diferentes cadeias da proteína. A repetição desses mesmos resíduos em múltiplas cadeias reflete a elevada simetria estrutural característica do capsídeo do adenovírus, indicando que regiões estruturalmente equivalentes desempenham papéis semelhantes na organização da rede.

A centralidade de autovetor apresentou comportamento distinto da centralidade de grau. Os maiores valores concentraram-se principalmente em resíduos pertencentes à mesma comunidade identificada pelo algoritmo Louvain, sugerindo a existência de regiões densamente conectadas internamente. Esse resultado indica que esses resíduos não apenas possuem elevado número de conexões, mas também encontram-se conectados a outros resíduos igualmente importantes, caracterizando regiões de elevada coesão estrutural.

Por sua vez, a centralidade de intermediação destacou resíduos diferentes daqueles identificados pelas demais métricas. Em especial, observou-se que alguns resíduos apresentaram valores elevados de *betweenness* mesmo possuindo grau relativamente moderado. Esse comportamento evidencia a capacidade dessa medida em identificar vértices que atuam como pontos de ligação entre diferentes regiões da rede, desempenhando papel importante na comunicação estrutural entre comunidades.

Os valores obtidos para a centralidade de proximidade indicaram a existência de resíduos capazes de alcançar rapidamente os demais vértices da rede por meio dos menores caminhos. Como a rede construída apresentou um único componente conectado, essa métrica pôde ser calculada para todos os resíduos da estrutura, permitindo identificar regiões potencialmente centrais na organização global da proteína.

A Figura 5 apresenta a estrutura tridimensional da proteína 6B1T destacando, em vermelho, os resíduos com maior centralidade de grau.



Figura 5 – Estrutura tridimensional da proteína 6B1T. Os 20 resíduos com maior Degree Centrality são destacados em vermelho, enquanto os demais resíduos são representados em cinza.

De maneira geral, as diferentes medidas de centralidade forneceram informações complementares sobre a organização da rede. Enquanto a centralidade de grau identificou os resíduos mais conectados, a centralidade de autovetor destacou regiões altamente coesas, a centralidade de intermediação evidenciou possíveis pontos de ligação entre comunidades e a centralidade de proximidade identificou resíduos localizados em posições estrategicamente centrais na estrutura da proteína.

4.5 - Detecção de comunidades

Após a construção da rede e o cálculo das métricas topológicas, foi aplicada a detecção de comunidades utilizando o algoritmo Louvain. Esse algoritmo particiona a rede em grupos de vértices fortemente conectados internamente, buscando maximizar a modularidade da partição [6].

Para a rede construída com cutoff de 8 Å, o algoritmo identificou **33 comunidades**, valor compatível com a elevada complexidade estrutural da proteína 6B1T. A modularidade obtida foi de aproximadamente **0,90**, indicando uma forte organização modular da rede.

A tabela 4 foi elaborada a partir do arquivo *results/tables/6B1T_communities.csv*

Tabela 4 – Resumo das comunidades identificadas pelo algoritmo Louvain.

Métrica	Valor
Número de comunidades	33
Menor comunidade	143 resíduos
Maior comunidade	552 resíduos
Modularidade	0,9044

Observa-se que as comunidades apresentaram tamanhos variados, contendo entre 143 e 552 resíduos. Essa distribuição indica que o algoritmo identificou regiões estruturais de diferentes dimensões, sem produzir agrupamentos excessivamente pequenos ou uma única comunidade dominante.

Com o objetivo de avaliar a correspondência espacial das comunidades detectadas, os resultados do algoritmo Louvain foram projetados sobre a estrutura tridimensional da proteína. Cada comunidade foi representada por uma cor distinta, permitindo visualizar sua distribuição ao longo da molécula.




Figura 6 – Estrutura tridimensional da proteína 6B1T colorida de acordo com as comunidades detectadas pelo algoritmo Louvain.

A inspeção visual da Figura 6 mostra que as comunidades ocupam regiões espacialmente bem definidas da proteína, apresentando continuidade estrutural e pequena sobreposição entre si. Embora o algoritmo utilize exclusivamente informações topológicas da rede, a projeção tridimensional evidencia que os agrupamentos encontrados também apresentam coerência espacial, sugerindo que a modelagem por rede preservou características relevantes da organização estrutural da molécula.

Esse resultado é particularmente importante porque demonstra que a representação da proteína como uma rede de contatos foi capaz de capturar padrões estruturais consistentes sem utilizar informações funcionais ou conhecimento biológico prévio durante a etapa de particionamento. Dessa forma, a detecção de comunidades mostrou-se uma ferramenta promissora para identificar automaticamente regiões estruturalmente coesas em proteínas de grande porte.

Os resultados obtidos nesta etapa também fornecem uma base para aplicações futuras envolvendo identificação automática de domínios estruturais, análise de interfaces entre subunidades ou estudo de regiões potencialmente relevantes para processos de interação molecular, temas que poderão ser explorados em trabalhos posteriores mediante validação biológica específica.

4.6 - Validação biológica e estrutural

A etapa final da análise consistiu em comparar qualitativamente as comunidades detectadas pelo algoritmo Louvain com a organização estrutural conhecida da proteína 6B1T. Embora este trabalho não tenha realizado uma validação quantitativa utilizando anotações funcionais específicas, a inspeção visual da estrutura tridimensional permitiu avaliar a coerência espacial dos agrupamentos identificados.

A estrutura 6B1T corresponde ao capsídeo do Adenovírus Humano tipo 5, composto por múltiplas cópias de proteínas organizadas de forma altamente simétrica [9]. Essa característica estrutural torna a proteína um cenário adequado para avaliar se a modelagem baseada em redes é capaz de identificar regiões espacialmente organizadas a partir exclusivamente das relações de proximidade entre resíduos.

A projeção das comunidades detectadas sobre a estrutura tridimensional mostrou que os agrupamentos obtidos pelo algoritmo Louvain apresentam, em sua maioria, continuidade espacial e limitada sobreposição entre regiões vizinhas. Esse comportamento indica que a rede construída preservou adequadamente as relações estruturais existentes na proteína, permitindo que o algoritmo identificasse agrupamentos consistentes apenas a partir das conexões estabelecidas entre os resíduos.

Além disso, observou-se que resíduos estruturalmente equivalentes pertencentes a diferentes cadeias frequentemente apresentaram comportamentos semelhantes nas análises de centralidade e na organização das comunidades. Esse resultado é compatível com a elevada simetria do capsídeo viral, no qual diversas proteínas repetem praticamente a mesma organização estrutural ao longo da partícula.

Embora não seja possível afirmar que cada comunidade identificada corresponda diretamente a um domínio funcional específico, os resultados obtidos sugerem que a modelagem por redes complexas foi capaz de capturar padrões relevantes da organização estrutural da proteína. Dessa forma, a metodologia desenvolvida mostrou-se adequada para representar a arquitetura da estrutura 6B1T e produzir agrupamentos espacialmente coerentes.

A comparação qualitativa entre as comunidades detectadas e a estrutura tridimensional reforça que a representação da proteína como uma rede de contatos constitui uma abordagem eficaz para investigar sua organização topológica. Trabalhos futuros poderão aprofundar essa análise por meio da comparação quantitativa com domínios estruturais anotados no Protein Data Bank ou com outras bases de dados especializadas, permitindo avaliar de forma mais precisa a correspondência entre as comunidades detectadas e as regiões funcionais da proteína.

5 - Limitações

Embora os resultados obtidos demonstrem que a metodologia proposta foi capaz de representar adequadamente a estrutura da proteína 6B1T e identificar comunidades estruturalmente coerentes, algumas limitações devem ser consideradas na interpretação dos resultados.

A primeira limitação refere-se ao modelo de rede adotado. Neste trabalho, as conexões entre os resíduos foram definidas exclusivamente com base na proximidade espacial entre seus átomos C α , utilizando um limiar fixo de distância. Essa abordagem simplifica a construção da rede e é amplamente empregada na literatura [5]–[7], porém não considera características físico-químicas das interações, como ligações de hidrogênio, interações hidrofóbicas, cargas elétricas ou afinidades específicas entre aminoácidos.

Outra limitação está relacionada à representação utilizada. Cada resíduo foi modelado como um único vértice da rede, representado pelo átomo C α . Embora essa simplificação reduza significativamente o custo computacional e preserve a organização estrutural global da proteína, ela não representa detalhes das interações em nível atômico.

Em relação às métricas topológicas, a centralidade de intermediação (*Betweenness Centrality*) foi calculada por meio de uma aproximação baseada em amostragem. Essa escolha foi motivada pelo elevado custo computacional da versão exata para redes contendo mais de doze mil vértices. Ainda assim, a aproximação utilizada mostrou-se suficiente para identificar resíduos potencialmente importantes como pontos de ligação entre diferentes regiões da rede.

Por fim, a avaliação das comunidades identificadas foi realizada de forma qualitativa, por meio da inspeção visual da estrutura tridimensional da proteína. Não foram realizadas comparações quantitativas com domínios estruturais ou anotações funcionais disponíveis em bases especializadas, o que poderá ser explorado em trabalhos futuros para validar de forma mais detalhada a correspondência entre as comunidades detectadas e a organização funcional da proteína.

Apesar dessas limitações, acredita-se que a metodologia desenvolvida atingiu os objetivos propostos, fornecendo uma representação consistente da estrutura da proteína e permitindo a aplicação de técnicas clássicas de análise de redes complexas em uma estrutura biológica de grande porte.

6 - Declaração de Colaboração e Uso de Inteligência Artificial

O desenvolvimento deste projeto foi realizado individualmente. Durante sua execução foram realizadas discussões de caráter geral com colegas da disciplina sobre conceitos relacionados à modelagem de redes e ao funcionamento dos algoritmos estudados, sem compartilhamento de código-fonte ou de resultados experimentais.

Como ferramenta de apoio ao desenvolvimento, foi utilizado o modelo **ChatGPT (OpenAI GPT-5.5)** para auxílio na revisão textual do relatório, esclarecimento de dúvidas conceituais, organização da estrutura do código e discussão de alternativas de implementação. Todas as decisões metodológicas, a implementação final em Python, a execução dos experimentos, a análise dos resultados e a redação final do trabalho foram realizadas pelo autor.

O uso da ferramenta teve caráter exclusivamente auxiliar, sendo empregado de forma semelhante à consulta de documentação técnica, livros ou outras fontes de apoio ao desenvolvimento do projeto.

Agradeço ao colega Eduardo dos Santos Rocha pelas discussões sobre a implementação do projeto, pelas sugestões técnicas e pela troca de experiências que contribuíram para o desenvolvimento deste trabalho.

7 - Conclusão

Este trabalho apresentou uma abordagem baseada em Redes Complexas para a modelagem e análise estrutural da proteína 6B1T, correspondente ao capsídeo do Adenovírus Humano tipo 5. A metodologia proposta permitiu representar a proteína como uma rede de contatos entre resíduos, possibilitando a aplicação de métricas clássicas de análise topológica e de algoritmos de detecção de comunidades.

Inicialmente, todo o pipeline computacional foi validado utilizando a proteína 1UBQ, garantindo o correto funcionamento das etapas de leitura dos arquivos PDB, construção da rede e cálculo das métricas. Em seguida, a metodologia foi aplicada à proteína-alvo, resultando na construção de uma rede composta por **12.544 vértices** e **66.809 arestas**, representando adequadamente a organização espacial da estrutura analisada.

Os experimentos realizados permitiram avaliar a influência do limiar de distância na construção da rede, justificando a adoção de um cutoff de **8 Å** como compromisso entre conectividade, modularidade e custo computacional. A análise topológica mostrou que a rede apresenta organização estrutural consistente, enquanto as diferentes medidas de centralidade evidenciaram resíduos com papéis distintos na conectividade global, na coesão local e na intermediação entre diferentes regiões da estrutura.

A aplicação do algoritmo Louvain resultou na identificação de **33 comunidades**, as quais apresentaram boa coerência espacial quando projetadas sobre a estrutura tridimensional da

proteína. Embora este trabalho não tenha realizado uma validação quantitativa com domínios estruturais anotados, a inspeção visual indicou que os agrupamentos obtidos representam regiões estruturalmente organizadas, demonstrando o potencial da modelagem por redes para investigar a arquitetura de proteínas de grande porte.

De forma geral, os objetivos propostos foram atingidos. Além de consolidar conceitos fundamentais de Redes Complexas, como modelagem de grafos, medidas de centralidade e detecção de comunidades, o trabalho demonstrou a viabilidade da aplicação dessas técnicas na análise de estruturas proteicas reais. A metodologia desenvolvida também estabelece uma base que poderá ser expandida em estudos futuros, incorporando critérios mais sofisticados de construção da rede e procedimentos quantitativos de validação biológica.

Referências Bibliográficas

- [1] A.-L. Barabási, *Network Science*. Cambridge, UK: Cambridge University Press, 2016.
- [2] A.-L. Barabási and R. Albert, "Emergence of scaling in random networks," *Science*, vol. 286, no. 5439, pp. 509–512, 1999.
- [3] M. E. J. Newman, *Networks: An Introduction*. Oxford, UK: Oxford University Press, 2010.
- [4] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre, "Fast unfolding of communities in large networks," *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2008, no. 10, P10008, 2008.
- [5] G. Amitai, A. Shemesh, E. Sitbon, M. Shklar, D. Netanel, I. Venger, and S. Pietrokovski, "Network analysis of protein structures identifies functional residues," *Journal of Molecular Biology*, vol. 344, no. 4, pp. 1135–1146, 2004.
- [6] L. H. Greene and V. A. Higman, "Uncovering network systems within protein structures," *Journal of Molecular Biology*, vol. 334, no. 4, pp. 781–791, 2003.
- [7] L. Di Paola and A. Giuliani, "Protein Contact Network Topology: A Natural Language for Allostery," *Current Opinion in Structural Biology*, vol. 31, pp. 43–48, 2015.
- [8] S. K. Burley et al., "RCSB Protein Data Bank: Biological macromolecular structures enabling research and education in fundamental biology, biomedicine, biotechnology and energy," *Nucleic Acids Research*, vol. 47, no. D1, pp. D464–D474, 2019.
- [9] X. Dai, L. Wu, R. Sun, and Z. H. Zhou, "Atomic Structures of Minor Proteins VI and VII in Human Adenovirus," *Journal of Virology*, vol. 91, no. 24, e00850-17, 2017.
- [10] P. J. A. Cock et al., "Biopython: Freely available Python tools for computational molecular biology and bioinformatics," *Bioinformatics*, vol. 25, no. 11, pp. 1422–1423, 2009.
- [11] A. A. Hagberg, D. A. Schult, and P. J. Swart, "Exploring network structure, dynamics, and function using NetworkX," in *Proceedings of the 7th Python in Science Conference (SciPy 2008)*, Pasadena, CA, USA, 2008, pp. 11–15.

- [12] P. Virtanen et al., “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [13] C. R. Harris et al., “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
- [14] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proceedings of the 9th Python in Science Conference (SciPy 2010)*, Austin, TX, USA, 2010, pp. 56–61.